TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI

HỌC PHẦN CHUYÊN ĐỀ CÔNG NGHỆ THÔNG TIN

03 PROJECT

Xây dựng hệ thống Hybrid RAG với các chiến lược Chunking

Hà Nội, 2026

1. Giới thiệu

Mỗi học viên lựa chọn và thực hiện 01 trong 03 đề tài dưới dạng một ứng dụng hoàn chỉnh. Mục tiêu chính là xây dựng hệ thống cho phép người dùng nhập câu hỏi, tìm kiếm trên tập dữ liệu do nhóm thu thập và nhận câu trả lời có căn cứ từ nguồn tài liệu.

Project không yêu cầu huấn luyện một mô hình ngôn ngữ từ đầu; học viên sử dụng mô hình embedding và LLM đã được huấn luyện sẵn để xây dựng pipeline Retrieval-Augmented Generation (RAG).

Ba project được thiết kế dựa trên các nội dung đã học: **Semantic Search, FAISS, BM25, Hybrid Search bằng RRF, RAG trên PDF, Chunking và Metadata.**

- Vận dụng đầy đủ pipeline: đọc tài liệu → làm sạch dữ liệu → chunking → embedding/index → Hybrid Search → tạo context → LLM sinh câu trả lời.
- Hiểu ảnh hưởng của chiến lược chunking đến chất lượng Retrieval và RAG.
- Biết tổ chức metadata để truy vết nguồn, số trang và hợp nhất kết quả BM25/FAISS đúng theo chunk_id.
- Biết xây dựng tập câu hỏi đánh giá và phân tích định lượng/định tính thay vì chỉ trình diễn một vài ví dụ.

2. Tóm tắt ba project

Project	Tên ứng dụng	Nguồn dữ liệu gợi ý	Chức năng trọng tâm	Loại Chiến lược Chunking
1	Trợ lý hỏi đáp tài liệu học tập	Giáo trình, bài giảng, course notes	Tra cứu khái niệm, giải thích, so sánh, tìm chương/trang	Tự chọn (Fixed-size, Recursive, Semantic, …)
2	Cổng tra cứu thông tin, thông báo, quy định và văn bản của nhà trường	Thông báo, quyết định, quy chế, thông tư, hướng dẫn, trang web chính thức	Tìm đúng văn bản; trích số/ký hiệu, ngày ban hành, đơn vị ban hành, thời hạn và quy trình, trang tài liệu	Tự chọn (Fixed-size, Recursive, Semantic, …)
3	Trợ lý nghiên cứu đa tài liệu	Bài báo, báo cáo, tài liệu kỹ thuật	Tìm kiếm, so sánh và tổng hợp thông tin từ nhiều nguồn	Tự chọn (Fixed-size, Recursive, Semantic, …)

3. Yêu cầu kỹ thuật chung cho cả ba project

3.1. Dữ liệu

- Sử dụng tối thiểu 02 tài liệu PDF, tổng dung lượng nội dung tối thiểu khoảng 30 trang. Có thể dùng tài liệu tiếng Việt, tiếng Anh hoặc song ngữ.
- Tài liệu phải có nguồn rõ ràng và được phép sử dụng cho mục đích học tập.
- Phải đọc PDF theo từng trang để giữ metadata; không chỉ nối toàn bộ PDF thành một chuỗi duy nhất.
- Phải xử lý tối thiểu các lỗi cơ bản khi trích xuất PDF: khoảng trắng dư thừa, dòng trống dư thừa và từ bị ngắt dòng nếu có.

3.2. Metadata và yêu cầu truy vết nguồn

Mỗi chunk phải lưu tối thiểu các trường sau:

```
chunk = {
    "chunk_id": 17,
    "text": "...",
    "source": "document.pdf",
    "page": 5,
    "section": "...",
    "strategy": "recursive"
}
```

- source và page dùng để người dùng mở lại tài liệu và kiểm tra câu trả lời.
- section/title dùng để chỉ đúng mục, chương hoặc điều khoản trong tài liệu.
- chunk_id phải thống nhất giữa BM25 và FAISS để RRF hợp nhất đúng cùng một nội dung (Nếu lựa chọn Hybrid Search).
- Có thể bổ sung document_id, source_url, start_page/end_page, issue_date, category hoặc các trường đặc thù của từng project.

Đối với văn bản hành chính/pháp quy, citation phải thể hiện đúng loại văn bản và định danh, ví dụ: "Quyết định số 123/QĐ-ĐHGTVT ngày 15/03/2026, trang 2, Mục II" hoặc "Thông tư số 08/2021/TT-BGDĐT, Điều 12".

3.3. Pipeline Retrieval và RAG

- Tạo embedding cho toàn bộ chunk bằng một SentenceTransformer phù hợp với ngôn ngữ của tài liệu và câu hỏi.
- Học viên được lựa chọn một trong hai phương án Retrieval:

- **Phương án 1 - Semantic Search**

  Xây dựng FAISS index từ embedding của các chunk.

  Chuyển câu hỏi của người dùng thành embedding bằng cùng mô hình.

  Tìm Top-K chunk có độ tương đồng ngữ nghĩa cao nhất.

- **Phương án 2 - Hybrid Search**

  Xây dựng FAISS cho Semantic Search.

  Xây dựng BM25 cho Keyword Search.

  BM25 và FAISS phải sử dụng đúng cùng một tập chunk và cùng hệ thống chunk_id.

  Hợp nhất kết quả từ BM25 và FAISS bằng Reciprocal Rank Fusion - RRF.

  Cấu hình tham khảo: BM25 Top-8 và FAISS Top-8 → RRF → chọn Top-3 hoặc Top-5 chunk.

- Học viên phải trình bày rõ phương án Retrieval đã lựa chọn, lý do lựa chọn và các tham số được sử dụng như Top-K, embedding model, FAISS index hoặc tham số RRF.
- Prompt yêu cầu LLM chỉ trả lời từ context, báo thiếu thông tin khi context không đủ và trích dẫn source/page.

```
BM25 Top-N candidates
          \
           RRF  →  Top-K chunks  →  Context  →  LLM Answer
          /
FAISS Top-N candidates
```

3.4. Yêu cầu đánh giá

- Xây dựng tối thiểu 15 câu hỏi: 05 câu khớp từ khóa, 05 câu diễn đạt lại theo ngữ nghĩa và 05 câu cần tổng hợp nhiều thông tin.
- Với mỗi câu hỏi, xác định ground truth source/page/section hoặc văn bản liên quan.
- Báo cáo tối thiểu Precision@3 và Recall@3; khuyến khích thêm Hit@3, MRR, nDCG, thời gian truy vấn và số token context.
- Đánh giá câu trả lời theo tính đúng, đầy đủ, bám nguồn và độ chính xác của citation.
- Phân tích ít nhất 03 trường hợp: một trường hợp tốt, một trường hợp thất bại và một trường hợp hai chiến lược cho kết quả khác nhau rõ rệt.

4. PROJECT 1 - TRỢ LÝ HỎI ĐÁP TÀI LIỆU HỌC TẬP

4.1. Mục tiêu và dữ liệu

Xây dựng ứng dụng giúp sinh viên tìm kiếm và hỏi đáp trên giáo trình, bài giảng hoặc course notes của một hoặc nhiều học phần. **Ứng dụng phải giúp người dùng biết câu trả lời nằm ở tài liệu nào, chương/mục nào và trang nào.**

- Dữ liệu gợi ý: Machine Learning, Data Science, Mạng máy tính, Cơ sở dữ liệu, Lập trình, An toàn thông tin...
- Tài liệu nên có định nghĩa, công thức, ví dụ và các phần giải thích liên tiếp để kiểm tra khả năng giữ ngữ cảnh.

Metadata:

Tên trường	Ý nghĩa	Tên trường	Ý nghĩa
document_title	Tên giáo trình/tài liệu	course	Tên học phần
author/year	Tác giả và năm	chapter/section/page	Chương, mục và trang

4.2. Chức năng bắt buộc

- Hỏi định nghĩa, giải thích khái niệm, tìm ví dụ, so sánh hai khái niệm và tìm nội dung theo chương/trang.
- Hiển thị câu trả lời kèm tên tài liệu, chương/mục và số trang.
- Cho phép xem Top-K đoạn liên quan trước hoặc sau khi LLM sinh câu trả lời.
- Cho phép thử ít nhất 02 phương án chunking để so sánh.
- Có thống kê số chunk, độ dài trung bình và thời gian truy vấn.

Ví dụ citation mong đợi: "Gradient Descent cập nhật tham số theo hướng ngược gradient. Nguồn: COS 324 Course Notes, Section 3.2, trang 27."

4.3. Yêu cầu nghiệm thu riêng

- Có ít nhất 03 câu hỏi nhiều thành phần cần lấy thông tin từ nhiều chunk.
- Có phân tích trường hợp chunk quá nhỏ, quá lớn hoặc overlap gây trùng lặp.
- Kết luận chiến lược chunking phải dựa trên Retrieval metrics và chất lượng câu trả lời, không chỉ dựa trên trực quan.

5. PROJECT 2 - CỔNG TRA CỨU THÔNG TIN, THÔNG BÁO VÀ VĂN BẢN CỦA NHÀ TRƯỜNG

5.1. Mục tiêu và dữ liệu

Xây dựng ứng dụng tìm kiếm và hỏi đáp trên các nguồn thông tin chính thức của nhà trường hoặc cơ quan quản lý giáo dục. **Mục tiêu không chỉ trả lời nội dung, mà còn phải xác định đúng văn bản làm căn cứ: loại văn bản, số/ký hiệu, ngày ban hành, cơ quan ban hành, điều/mục và trang liên quan.**

- Dữ liệu gợi ý: thông báo học phí, đăng ký học phần, lịch thi, học bổng, cẩm nang sinh viên, quy chế đào tạo, quyết định, thông tư, hướng dẫn thủ tục hành chính.
- Nguồn có thể là PDF và trang web chính thức; nếu dùng web phải lưu URL và ngày truy cập.
- Khuyến khích chọn một phạm vi rõ ràng, ví dụ "Thông tin dành cho sinh viên", "Quy chế đào tạo" hoặc "Thủ tục hành chính".

Metadata cho văn bản hành chính:

Tên trường	Ý nghĩa	Tên trường	Ý nghĩa
document_type	Quyết định/Thông tư/Thông báo...	number_symbol	Số và ký hiệu văn bản
title_subject	Trích yếu hoặc chủ đề	issue_date	Ngày ban hành
issuing_authority	Cơ quan/đơn vị ban hành	effective_date/deadline	Ngày hiệu lực hoặc hạn cuối
page/section	Trang, điều, khoản, mục	source_url	Link hoặc file gốc

5.2. Chức năng

- Tìm kiếm theo câu hỏi tự nhiên, từ khóa, loại văn bản, số/ký hiệu văn bản, ngày ban hành hoặc chủ đề.
- Trả về đúng văn bản có liên quan và hiển thị các thông tin nhận dạng văn bản.
- Trích xuất và trả lời các trường thông tin khi có trong tài liệu: đối tượng áp dụng, thời hạn, mức phí, điều kiện, ngoại lệ và các bước thực hiện.
- Cho phép lọc theo loại văn bản, đơn vị ban hành, khoảng thời gian hoặc danh mục.
- Khi có nhiều văn bản cùng chủ đề, phải phân biệt văn bản nào mới hơn, văn bản nào thay thế hoặc bổ sung nếu metadata có đủ thông tin.

- Khi câu hỏi không có trong corpus, phải từ chối suy đoán và hướng dẫn kiểm tra nguồn chính thức.

Ví dụ câu hỏi kiểm thử:

- Hạn đóng học phí học kỳ I năm học 2026-2027 là ngày nào và căn cứ theo thông báo nào?
- Quy trình xin bảo lưu kết quả học tập gồm những bước nào?
- Theo Thông tư số .../TT-BGDĐT, điều kiện công nhận tốt nghiệp là gì?
- Quyết định nào quy định mức học phí và quyết định đó được ban hành ngày nào?
- Thông báo số ... áp dụng cho đối tượng sinh viên nào?

Ví dụ định dạng citation:

```
Nguồn: Quyết định số 123/QĐ-ĐHGTVT ngày 15/03/2026
Cơ quan ban hành: Trường Đại học Giao thông Vận tải
Vị trí: Điều 4, trang 3
Liên kết: https://...
```

6. PROJECT 3 - TRỢ LÝ NGHIÊN CỨU ĐA TÀI LIỆU

6.1. Mục tiêu và dữ liệu

Xây dựng ứng dụng hỗ trợ đọc, tìm kiếm, so sánh và tổng hợp thông tin trên nhiều bài báo, báo cáo hoặc tài liệu kỹ thuật cùng lĩnh vực. Câu trả lời phải chỉ rõ ý nào được lấy từ nguồn nào và không được gộp các kết luận khác nhau thành một khẳng định không có căn cứ.

- Dữ liệu gợi ý: AI, Computer Vision, NLP, IoT, An toàn thông tin, giao thông thông minh, giáo dục số...
- Sử dụng tối thiểu 03 tài liệu; ưu tiên các tài liệu cùng lĩnh vực nhưng khác phương pháp hoặc chủ đề con.

Ví dụ Metadata:

Tên trường	Ý nghĩa	Tên trường	Ý nghĩa
title	Tên bài báo/báo cáo	authors	Tác giả
year	Năm công bố	venue	Tạp chí hoặc hội nghị
document_type	Paper/Report/Technical note	section/page	Mục và trang
doi/url	DOI hoặc liên kết gốc	source	Tên file/tài liệu

6.2. Chức năng bắt buộc

- Truy vấn trên toàn bộ corpus hoặc giới hạn theo một số tài liệu được chọn.
- Hỏi về khái niệm, phương pháp, dữ liệu, kết quả thực nghiệm, ưu điểm, hạn chế và kết luận.
- Hỗ trợ câu hỏi so sánh hai hoặc nhiều phương pháp/tài liệu.
- Khi tổng hợp từ nhiều nguồn, câu trả lời phải gắn citation cho từng ý hoặc từng nhóm ý.
- Hiển thị danh sách tài liệu đã sử dụng gồm tiêu đề, tác giả, năm, trang/section và DOI/URL.
- Khuyến khích chức năng upload tài liệu, lựa chọn corpus và lưu notebook nghiên cứu cá nhân.

Ví dụ citation: "Phương pháp A sử dụng backbone Transformer và đạt 91,2% accuracy [Nguyen et al., 2024, Section 4.2, trang 8]. Phương pháp B ưu tiên tốc độ suy luận [Tran et al., 2023, trang 6]."

6.3. Chunking

- Semantic hoặc Recursive Chunking là hai lựa chọn; nếu dùng Semantic phải giải thích threshold/percentile và giới hạn độ dài.
- So sánh chiến lược chính với ít nhất 01 baseline trên cùng tập câu hỏi.
- Có ít nhất 05 câu hỏi cần tổng hợp từ hai nguồn trở lên và 03 câu hỏi so sánh phương pháp.
- Đánh giá citation correctness: nguồn được gắn có thực sự chứa thông tin được trích dẫn hay không.

7. Sản phẩm

STT	Sản phẩm	Yêu cầu
1	Mã nguồn ứng dụng	Chạy được; code có tổ chức; không chứa API key.
2	Link demo hoặc video demo	Web chạy được hoặc video 5-8 phút thể hiện luồng sử dụng, nguồn trích dẫn và ít nhất một trường hợp thất bại.
3	Notebook/Script xử lý dữ liệu	Đọc dữ liệu, làm sạch, chunking, embedding, BM25/FAISS, RRF, đánh giá.
4	Báo cáo PDF	Khuyến nghị 8-15 trang: bài toán, dữ liệu, thiết kế, thực nghiệm, kết quả, hạn chế và kết luận.
5	Tập câu hỏi đánh giá CSV/XLSX	Có query, loại query, ground truth source/page/section và kết quả metrics.
6	Slide trình bày	Khuyến nghị 8-12 slide, tập trung vào ứng dụng, thiết kế, kết quả và demo.
7	README	Hướng dẫn cài đặt, cấu hình API key, cách chạy và cấu trúc thư mục.